

Introducción a las Series de tiempo Taller

Melanie Oyarzún W.
`melanie.oyarzun@ucv.cl`

Bibliografía recomendada:

Wooldridge, c.12

Stock Watson, c.14

Gujarati, c.12

Diciembre 2021

Outline

- 1 Introducción
- 2 Conceptos fundamentales
- 3 Modelos de Series de tiempo
 - Series Estacionarias
 - Correlación Serial

La naturaleza de los datos: I

Hasta ahora nos hemos concentrado en datos de corte transversal, principalmente...

La naturaleza de los datos: II

Datos de tipo corte transversal: encuesta CASEN

indiv	sexo	edad	escolaridad	ingreso
1	hombre	41	7	243100
2	mujer	19	12	143650
3	hombre	33	12	.
4	hombre	64	12	377001
5	hombre	37	12	205400
6	mujer	62	12	265200
7	hombre	16	11	.
8	hombre	22	1	.
9	mujer	50	20	663000
10	hombre	45	19	663000
11	hombre	46	12	410800
12	hombre	17	11	.
13	mujer	23	16	.
14	hombre	43	11	232050
15	hombre	29	12	.
16	hombre	5	.	.
17	mujer	37	13	.
18	mujer	3	.	.
19	hombre	44	16	1326000
20	mujer	37	8	.


*Unidad de observación:
individuos*

*Cada fila representa un
individuo (personas,
familias, empresas) en un
momento del tiempo (en el
mismo año, mes, etc.)*

*Ejemplo: variable edad
contiene la edad de 20
personas en la muestra*

Corte Transversal y Series de tiempo I

En corte transversal:



- Estimamos modelos de la forma:

$$y_i = \beta_0 + \beta_1 x_{1i} + \cdots + \beta_k x_{ki} + u_i$$


- Supuesto de muestra aleatoria implica que cada observación es independiente:

Corte Transversal y Series de tiempo II

- 1 (supuesto de exogeneidad) $E[u_i|X_i] = 0$
- 2 (i.id., por muestreo aleatorio) $E[u_i|X_j] = 0$

Corte Transversal y Series de tiempo III

En series de tiempo:



- Estimamos modelos de la forma:

$$y_t = \beta_0 + \beta_1 x_{1t} + \cdots + \beta_k x_{kt} + u_t$$

- Cada observación es el resultado de un proceso estocástico
- No son independientes (vienen del mismo proceso)
- Requieren un supuesto más estricto:
 - (supuesto de exogeneidad)
$$E[u_t | X_s] = 0 \quad \forall s$$

Proceso Estocástico I

- O proceso de serie temporal: sucesión de variables aleatorias indicadas por el momento en el tiempo (y_t, z_t, x_t)
- En cada momento se observa un posible resultado (o realización) del proceso estocástico.

Proceso Estocástico II

Ejemplos:

- Modelo estático
 - Se modela la relación contemporánea entre dos variables, i.e., relación en el mismo momento en el tiempo

$$y_t = \beta_0 + \beta_1 z_t + u_t$$

- Ejemplos:

$$\text{inflación}_t = \beta_0 + \beta_1 \text{desempleo}_t + u_t$$

- Múltiple:

$$\text{homicidio}_t = \beta_0 + \beta_1 \text{condena}_t + \beta_2 \text{desmepleo}_t + \beta_3 \text{hombres}_t + u_t$$

Conceptos importantes I

Rezagos

- Variables de series de tiempo se denominan con sub-índice t para indicar el período en el tiempo: y_t
- El valor “rezagado” es el valor de la variable en períodos anteriores: y_{t-1} es el valor 1 período anterior, y_{t-2} es el valor 2 períodos atrás, , y_{t-j} es el valor j períodos atrás.

Diferencias

- Cambio en y entre el período $t-1$ y t , se indica con Δ

$$\Delta y_t = y_t - y_{t-1}$$

Tasas de Crecimientos

Conceptos importantes II

- Primera diferencia en logs:

$$\Delta \ln(y_t) = \ln(y_t) - \ln(y_{t-1})$$

- Cambio porcentual de y_t entre $t - 1$ y $t \approx 100 \times \Delta \ln(y_t)$

Correlación serial

- Muchas variables de series de tiempo están relacionadas con sus valores pasados.
- Razones: inercia, reacciones rezagadas, entre otras.
- Esta relación con el pasado se conoce como **autocorrelación**.
- Si los valores de una variable X en el presente están correlacionados con valores pasados de otra variable, Y , se conoce como **correlación serial**.
- A veces se usan los términos como sinónimos.

Supuestos de Gauss Markov

- 1 Modelo lineal en parámetros

$$y_t = \beta_0 + \beta_1 x_{1t} + \cdots + \beta_k x_{kt} + u_t$$

- 2 Media condicionada nula (exogeneidad estricta)

$$E[u_t | X_{js}] = 0 \quad \forall s$$

- 3 No hay colinealidad perfecta.

- 4 Homoscedasticidad

$$\text{Var}[u_t | X_{js}] = \sigma^2 \quad \forall s$$

- 5 No hay correlación serial.

$$\text{Cov}[u_t, u_s | X_{js}] = 0 \quad \forall s \neq t$$

1 a 3 implican que $\hat{\beta}_{MCO}$ es insesgado y 4-5 implican que es eficiente.
(1 a 5 implican que son MELI)

Exogeneidad Estricta

- Ejemplos: ¿cuándo falla supuesto de exogeneidad estricta?
 - Efecto rezagado (variable independiente rezagada)
 - Retroalimentación entre variables
 - Auto-dependencia (variable dependiente rezagada, AR(1))
- Implicancia: $E(\hat{\beta}_{ols}|X) \neq \beta$ (sesgado)
- ¿Cómo se resuelve?
- Bajo ciertos supuestos, aún cuando $E(\hat{\beta}_{ols}|X) \neq \beta$ (es sesgado), ocurre que $E(\hat{\beta}_{ols}|X) \rightarrow^p \beta$ (es consistente) cuando $n \rightarrow \infty$
- Se deben cumplir supuestos asintóticos (en muestra grande)

Supuestos Asintóticos

- 1 Modelo lineal en parámetros
- 2 Estacionareidad y dependencia débil
- 3 Exogeneidad “débil” ($E[u_t X_{jt}] = 0$)
- 4 No hay colinealidad perfecta.
- 5 Homoscedasticidad
- 6 No hay correlación serial.

Estacionariedad: I

“el pasado es similar al futuro”

- ❶ $E[X_t] = \mu$
- ❷ $Var[X_t] = \sigma^2$
- ❸ $Cov[X_t, X_{(t+h)}] = f(h)$ y $\neq g(t)$

Dependencia débil: (“el presente está más correlacionado con el futuro inmediato que con el futuro lejano”)

$$corr[X_t, X_{(t+h)}] \rightarrow 0 \quad \text{cuando} \quad h \rightarrow \infty$$

Estacionareidad: II

“el pasado es similar al futuro”

Ejemplos de series estacionarias y débilmente dependientes:

- ❶ Modelo de Media Móvil MA(1)

$$X_t = \epsilon_t + \gamma\epsilon_{(t-1)} \quad \epsilon_t \sim iid(0, \sigma^2)$$

- ❷ Modelo Auto-regresivo AR(1)

$$X_t = \rho X_{(t-1)} + \epsilon_{(t)} \quad \epsilon_t \sim iid(0, \sigma^2)$$

Con condición de dependencia débil: $|\rho| < 1$

Series estacionarias y débil. dep.

Media Móvil- Ejemplo

$$X_t = \epsilon_t + \gamma\epsilon_{(t-1)} \quad \epsilon_t \sim iid(0, \sigma^2)$$

Ejemplos:

- $\Delta ddahelados_t = \epsilon_t - 0,5\epsilon_{t-1}$, donde $\epsilon_t = \Delta temperatura_t$
- $\Delta preciopetroleo_t = \epsilon_t + 0,5\epsilon_{t-1}$, donde $\epsilon_t = \Delta huracán_t$

Series estacionarias y débil. dep.

Modelo Auto-regresivo -AR(1)- Ejemplo

$$X_t = \alpha_0 + \rho X_{t-1} + \epsilon_t \quad \epsilon_t \sim iid(0, \sigma^2)$$

Ejemplos:

- $\Delta \text{preciopetroleo}_t = \alpha_0 + 0,5 \Delta \text{preciopetroleo}_{t-1} + \epsilon_t$, donde $\epsilon_t \sim iid(0, \sigma^2)$

Series estacionarias y débil. dep.

Diferencias

- $MA(1)$: memoria “corta”, impacto del shock no persiste mucho
- $AR(1)$: memoria “larga”, impacto del shock persiste (en teoría, persiste infinitamente)

Series estacionarias y débil. dep.

Propiedades MA(1)

$$X_t = \varepsilon_t + \gamma \varepsilon_{t-1} \quad \varepsilon_t \sim iid(0, \sigma^2)$$

$$E(X_t) = 0$$

$$\text{Var}[X_t] = \sigma^2(1 + \gamma^2)$$

$$\text{Cov}[X_t, X_{t-1}] = \gamma\sigma^2$$

✓ Estacionariedad

$$\text{Corr}[X_t, X_{t-1}] = \frac{\gamma\sigma^2}{\sigma^2(1 + \gamma^2)}$$

$$\text{Cov}[X_t, X_{t-2}] = 0 \rightarrow \text{Corr}[X_t, X_{t-2}] = 0$$

✓ Dependencia débil

Series estacionarias y débil. dep.

Propiedades AR(1)

$$X_t = \rho X_{t-1} + \varepsilon_t, \varepsilon_t \sim iid(0, \sigma^2)$$

$$E(X_t) = 0$$

$$\text{Var}[X_t] = \frac{\sigma^2}{(1 + \rho^2)}$$

$$\text{Cov}[X_t, X_{t-1}] = \frac{\rho \sigma^2}{(1 + \rho^2)}$$

✓ Estacionariedad

$$\text{Corr}[X_t, X_{t-1}] = \rho$$

$$\text{Corr}[X_t, X_{t-2}] = \rho^2$$

✓ Dependencia débil

Correlación Serial

- Hemos incorporado un supuesto adicional al modelo: **no correlación serial**, ahora lo revisaremos más a fondo.
- Definición: $cov(u_t, u_{t+j}) \neq 0$
- Ejemplo: errores AR(1)


$$u_t = \alpha + \rho u_{t-1} + \epsilon_t$$

$$\epsilon_t \sim iid(0, \sigma^2)$$

- *Intuición*: errores del presente están relacionados con errores futuros.
 - Visto de otra forma, errores del presente están relacionados con errores del pasado.
- Es un problema más propio de datos de series temporales

Correlación Serial

Presencia de correlación serial



Correlación Serial

Posibles fuentes

- **Variables omitidas:** muchas variables en series de tiempo son persistentes; si no se controla por alguna variable, la capta el error en el presente, y seguirá en el futuro.
- **Forma funcional** (mal especificada)
- **Error de medición en variable(s) independiente(s).** Si el error de medición persiste en el tiempo, también puede llevar a estructura de errores persistentes.

Correlación Serial I

Implicancias

- Sin correlación serial:

$$\text{var}(\hat{\beta}|x_t) = \text{var}\left(\frac{\sum_{t=1}^n (x_t - \bar{x})u_t}{STC_x}\right) = \frac{\sigma^2}{SCT_x}$$

- Con correlación serial:

- Por ejemplo: $\text{cov}(u_t, u_{t+j}) = \rho^j \sigma^2$

Correlación Serial II

Implicancias

$$var(\hat{\beta}|x_t) = var\left(\frac{\sum_{t=1}^n (x_t - \bar{x})u_t}{SST_x}\right) = \frac{\sigma^2}{SST_x}$$

$$var(\hat{\beta}|x_t) = \frac{\sigma^2}{SST_x} + \frac{2 \sum_{t=1}^{T-1} \sum_{j=1}^{T-t} (x_t - \bar{x})(x_{t+j} - \bar{x}) E[u_t, u_{t+j}]}{SST_x^2}$$

$$var(\hat{\beta}|x_t) = \underbrace{\frac{\sigma^2}{SST_x}}_{\text{Varianza MCO}} + \frac{2\sigma^2 \sum_{t=1}^{T-1} \sum_{j=1}^{T-t} (x_t - \bar{x})(x_{t+j} - \bar{x}) \rho^j}{SST_x^2}$$

Varianza
MCO

Correlación Serial III

Implicancias


- Es frecuente que $\rho^j > 0$ por lo tanto el segundo término suele ser positivo.
- La varianza estimada con MCO suele sub-estimar la varianza verdadera en presencia de autocorrelación.
- Estimadores MCO no son los más eficientes (en términos de varianza)

Correlación Serial I

Ej1: Remuneraciones y productividad

Correlación Serial II

Ej1: Remuneraciones y productividad



Correlación Serial III

Ej1: Remuneraciones y productividad


Source	SS	df	MS	Number of obs = 60		
Model	939.411921	1	939.411921	F(1, 58) = 211.66		
Residual	257.417986	58	4.43824114	Prob > F = 0.0000		
Total	1196.82991	59	20.2852527	R-squared = 0.7849		
				Adj R-squared = 0.7812		
				Root MSE = 2.1067		

remu	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]	
imacec	.4117452	.0283013	14.55	0.000	.355094	.4683963
_cons	59.95865	3.139917	19.10	0.000	53.67342	66.24388

predict uhat, residual

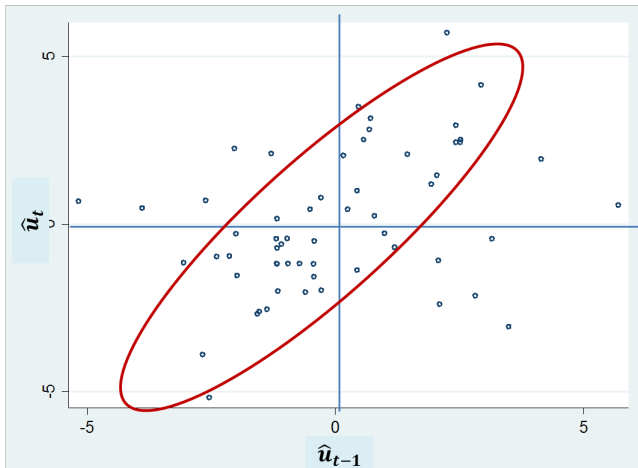
Correlación Serial IV

Ej1: Remuneraciones y productividad



Correlación Serial V

Ej1: Remuneraciones y productividad




Correlación Serial I

Ej2: Tipo de cambio y precio de cobre


Correlación Serial II

Ej2: Tipo de cambio y precio de cobre




Correlación Serial III

Ej2: Tipo de cambio y precio de cobre




Correlación Serial IV

Ej2: Tipo de cambio y precio de cobre




Correlación Serial V

Ej2: Tipo de cambio y precio de cobre




Correlación Serial VI

Ej2: Tipo de cambio y precio de cobre



Correlación Serial VII

Ej2: Tipo de cambio y precio de cobre



Correlación Serial

Detección

¿Cómo detectar si las variables tienen errores autocorrelacionados?

- Prueba Durbin-Watson
- Prueba de “rachas” (“runs” test)
- Prueba Breusch-Godfrey

Correlación Serial I

Detección: Prueba de Durbin-Watson

¿Cómo detectar si las variables tienen errores autocorrelacionados?
Una prueba paraétrica es la de Durbin-Watson:

- Modelo:

$$y_t = \beta_0 + \beta_1 x_{1t} + \cdots + \beta_k x_{kt} + u_t$$

$$u_t = \rho u_{t-1} + e_t$$

- El estadístico Durbin-Watson se define como:

$$DW = \frac{\sum_{t=2}^n (\hat{u}_t - \hat{u}_{t-1})^2}{\sum_{t=2}^n \hat{u}_t^2}$$

Correlación Serial II

Detección: Prueba de Durbin-Watson

- Es posible demostrar que: $DW \approx 2(1 - \hat{\rho})$
- Durbin y Watson encontraron la distribución de DW, la cual supone que se cumplen todos los supuestos clásicos del modelo MCO, incluyendo exogeneidad y normalidad (supuestos bastante exigentes).


Correlación Serial III

Detección: Prueba de Durbin-Watson

- Test (si la alternativa es correlación positiva):

$$H_0 : \rho = 0 \rightarrow dw = 2 \quad \text{vs.} \quad H_1 : \rho > 0 \rightarrow dw < 2$$

- Si d es significativamente $\neq 2$, se rechaza H_0 a favor de correlación $\neq 0$
- La distribución tiene regiones donde no se puede decidir (no es conclusivo)



- En stata: estat dwatson

Correlación Serial I

Detección: Prueba de “rachas”

¿Cómo detectar si las variables tienen errores autocorrelacionados?

Una primera prueba no paramétrica es la de “rachas”

- Una forma de pensar en el problema tiene que ver con observar el patrón de los residuos: $(+, +, +, +, -, -, +, +, \dots)$ o “rachas” que sería la sucesión ininterrumpida de un símbolo.
- Si no hay correlación serial, la probabilidad de $+$ en esta serie es independiente de la historia.
 - Si hay demasiadas rachas, sugiere correlación negativa.
 - Si hay muy pocas, sugiere correlación positiva.

Correlación Serial II

Detección: Prueba de “rachas”

- Existe un rango de valores de “rachas” para un período de n observaciones. Sean P y N el número de períodos con residuos positivos y negativos, respectivamente.
- Se puede demostrar que el número de rachas, R , está asintóticamente normalmente distribuido con:

$$E(R) = \frac{2NP}{N + P} + 1$$

$$V(R) = \frac{2NP(2NP - (N + P))}{(N + P)^2(N - 1)}$$

Correlación Serial III

Detección: Prueba de "rachas"

- Por lo que podemos hacer una prueba de hipótesis:

H_0 : Residuos independientes vs H_1 : residuos correlacionados

- Si las rachas observadas están en un intervalo entorno a un intervalo al valor esperado, no podemos rechazar la hipótesis nula.
- Realizamos un test z:

$$Z = \frac{R - E(R)}{SE(R)}$$

- Si Z es significativa, podemos rechazar la nula en favor de presencia de autocorrelación.

Correlación Serial IV

Detección: Prueba de “rachas”

En nuestro ejemplo:

	year	copper	exchrates	lpc	ltco	uhat	uhatlag	plusminus	newrun	runs
1	1994	2450	420.252	7.803843	6.040855	-.2207577	.	-	1	1
2	1995	3050	396.782	8.022897	5.983387	-.2698551	-.2207577	-	0	1
3	1996	2400	412.219	7.783224	6.021555	-.2408461	-.2698551	-	0	1
4	1997	2360	419.249	7.766417	6.038465	-.2245787	-.2408461	-	0	1
5	1998	1730	460.32	7.455877	6.131921	-.1429884	-.2245787	-	0	1
6	1999	1670	508.897	7.420579	6.232246	-.0440121	-.1429884	-	0	1
7	2000	1940	538.871	7.570443	6.289476	.0189445	-.0440121	+	1	2
8	2001	1690	634.429	7.432484	6.452724	.1769209	.0189445	+	0	2
9	2002	1670	689.242	7.420579	6.535593	.2593345	.1769209	+	0	2
10	2003	1880	691.536	7.539027	6.538915	.2671824	.2593345	+	0	2
11	2004	2950	609.55	7.989561	6.412721	.1582047	.2671824	+	0	2
12	2005	3830	559.863	8.25062	6.327692	.0831508	.1582047	+	0	2
13	2006	6940	530.263	8.845057	6.273373	.0515471	.0831508	+	0	2
14	2007	7230	522.691	8.885994	6.25899	.038728	.0515471	+	0	2
15	2008	7040	521.79	8.859364	6.257265	.0359852	.038728	+	0	2
16	2009	5320	559.667	8.579228	6.327343	.0953586	.0359852	+	0	2
17	2010	7680	510.377	8.946375	6.235149	.0171944	.0953586	+	0	2
18	2011	8950	483.364	9.099409	6.18077	-.0313368	.0171944	-	1	3
19	2012	8100	486.747	8.999619	6.187744	-.0281762	-.0313368	-	0	3

Tenemos 3 rachas, $P = 11$, $N = 8$ y $n = 19$.

Correlación Serial V

Detección: Prueba de "rachas"

Así:

$$E(R) = \frac{2 * 11 * 8}{19} + 1 = 10,26$$

$$SE(R) = \sqrt{\frac{2 * 11 * 8 * (2 * 11 * 8 - 19)}{19^2 * 18}} = 2,06$$

$$Z = \frac{3 - 10,26}{2,06} = -3,52$$

Como rechazamos, hay correlación serial. (y en este caso, es positiva)

Correlación Serial

Detección: Prueba de Breusch-Godfrey

- Realice la regresión por MCO de y_t sobre x_{1t}, \dots, x_{1kt} y obtenga los residuos.
- Efectuamos la regresión de \hat{u}_t sobre $x_{1t}, \dots, x_{1kt}, \hat{u}_{t-1}, \hat{u}_{t-2}, \dots, \hat{u}_{t-q}$ para toda $t = (q+1), \dots, n$
- Calcule el test F de significancia conjunta de que los rezagos del error son excluidos.
- En stata: estat bgodfrey, lag(q)